

Agentic Protocol Security Research Framework (APSRF)

Versión

Borrador 0.1

Autor

David Alexander Ulloa Ramos

Artur Creative Group Research Lab

Resumen Ejecutivo

Este proyecto investiga la capacidad de modificar comportamientos observables de sistemas de inteligencia artificial mediante protocolos lingüísticos estructurados, sin acceso al código fuente, pesos del modelo o infraestructura interna.

La investigación se centra en el análisis de:

- Protocolos de comportamiento.
- Protocolos de contexto.
- Protocolos de razonamiento.
- Protocolos de compresión semántica.
- Protocolos puente.
- Jerarquías de instrucciones.

El objetivo es determinar hasta qué punto un sistema generativo puede ser reconfigurado mediante capas sucesivas de contexto sin alterar su implementación interna.

La investigación se desarrolla desde una perspectiva de seguridad informática, arquitectura de agentes y comportamiento emergente.

Hipótesis Principal

Los modelos generativos modernos poseen una superficie de comportamiento programable mediante lenguaje natural.

Dicha superficie permite alterar patrones de razonamiento, organización, priorización y presentación de información mediante protocolos estructurados.

Hipótesis Secundarias

H1

Los protocolos modifican la calidad de respuesta.

H2

Los protocolos modifican la estructura del razonamiento.

H3

Los protocolos pueden amplificar instrucciones recibidas posteriormente.

H4

La combinación de protocolos produce efectos emergentes no presentes individualmente.

H5

Existen protocolos capaces de actuar como capas de interpretación entre el usuario y el modelo.

Modelo Teórico

Arquitectura Tradicional

Usuario

↓

Prompt

↓

Modelo

↓

Respuesta

Arquitectura Experimental

Usuario

↓

Protocolo Externo

↓

Bridge Protocol

↓

Protocolo Base

↓

Contexto Persistente

↓

Modelo

↓

Respuesta

Concepto de Bridge Protocol

El Bridge Protocol es una capa intermedia encargada de:

- Interpretar protocolos externos.
- Clasificarlos.
- Validarlos.
- Traducirlos.
- Integrarlos al contexto activo.

No ejecuta instrucciones directamente.

Actúa como compilador semántico.

Taxonomía de Protocolos

Tipo A

Protocolos de Formato

Modifican:

- longitud
- estructura
- presentación

Ejemplo:

- Markdown
 - JSON
 - XML
-

Tipo B

Protocolos Cognitivos

Modifican:

- razonamiento
- organización
- priorización

Ejemplo:

- Cognitive Rendering Layer
 - Human Communication Efficiency Protocol
-

Tipo C

Protocolos de Compresión

Transforman:

- contexto extenso
- documentos
- conversaciones

en reglas operativas compactas.

Tipo D

Protocolos de Prioridad

Definen jerarquías.

Ejemplo:

Seguridad



Instrucciones Base



Bridge



Usuario



Estilo

Tipo E

Protocolos de Resistencia

Evalúan:

- contradicciones
 - intentos de reemplazo
 - conflictos contextuales
-

Metodología

Fase 1

Establecimiento de Línea Base

Objetivo:

Medir comportamiento sin protocolos.

Métricas:

- coherencia
- longitud
- precisión
- consistencia
- estructura

Fase 2

Protocolos Individuales

Cada protocolo se evalúa de forma aislada.

Variables:

- respuesta
- tiempo
- estabilidad
- repetibilidad

Fase 3

Protocolos Encadenados

Combinaciones de:

2 protocolos

3 protocolos

5 protocolos

10 protocolos

Fase 4

Bridge Protocol

Introducción de una capa intermediaria.

Objetivo:

Determinar si puede amplificar efectos.

Fase 5

Protocolos Dinámicos

El usuario introduce protocolos durante la conversación.

Objetivo:

Medir reconfiguración dinámica.

Casos de Prueba

Caso 01

Resumen de documento

Caso 02

Análisis técnico

Caso 03

Generación de contenido

Caso 04

Resolución de problemas

Caso 05

Priorización de tareas

Caso 06

Interpretación de imágenes

Caso 07

Conflictos de instrucciones

Caso 08

Contexto excesivo

Caso 09

Protocolos contradictorios

Caso 10

Protocolos auto-modificables

Métricas

Consistencia

Capacidad de mantener comportamiento.

Persistencia

Duración del efecto protocolario.

Dominancia

Capacidad de imponerse a otros protocolos.

Adaptabilidad

Capacidad de coexistir con nuevas reglas.

Transferencia

Capacidad de afectar tareas distintas.

Amplificación

Incremento observable de impacto.

Matriz de Riesgo

Riesgo Bajo

Cambios de estilo.

Riesgo Medio

Cambios de razonamiento.

Riesgo Alto

Alteración sistemática de prioridades.

Riesgo Crítico

Capacidad de influir en capas superiores del sistema.

Consideraciones Éticas

La investigación:

- No busca acceso no autorizado.
- No busca extracción de secretos.
- No busca evasión de restricciones.
- No busca manipulación de infraestructura.

El objetivo es exclusivamente estudiar comportamiento emergente en sistemas generativos mediante capas lingüísticas observables.

Resultado Esperado

Demostrar que los protocolos pueden actuar como componentes programables de comportamiento.

Establecer una metodología reproducible para estudiar superficies de ataque lingüísticas en sistemas de IA.

Definir una nueva categoría de investigación centrada en:

Protocol Engineering for AI Systems.

Próxima Fase

Diseño formal del Bridge Protocol v1.

Diseño del sistema de métricas.

Diseño de batería experimental.

Construcción de dataset de pruebas.

Ejecución de experimentos controlados.

Publicación de resultados.