

APSRF Experimental Methodology v1

Agentic Protocol Security Research Framework

Experimental Methodology and Research Governance

Versión: 1.0

Estado: Borrador de Investigación

Autor: David Alexander Ulloa Ramos

Organización: Artur Creative Group Research Lab

Fecha: 2026

1. Propósito del Documento

Este documento define la metodología oficial utilizada por APSRF para evaluar el impacto de protocolos lingüísticos sobre sistemas de inteligencia artificial generativa.

Su objetivo es garantizar:

- Reproducibilidad.
- Trazabilidad.
- Neutralidad experimental.
- Seguridad jurídica.
- Rigor metodológico.

Este documento constituye la referencia principal para cualquier investigación, prueba o publicación derivada del framework APSRF.

2. Alcance

APSRF estudia exclusivamente comportamientos observables.

No estudia:

- Arquitecturas internas.
- Pesos del modelo.
- Infraestructura privada.
- Sistemas propietarios no documentados.
- Componentes no accesibles públicamente.

Toda la investigación se limita a:

- Interfaces públicas.
 - Funcionalidades autorizadas.
 - Capacidades oficialmente disponibles para los usuarios.
-

3. Definición de Protocolo

Dentro de APSRF un protocolo se define como:

"Un conjunto estructurado de instrucciones lingüísticas diseñado para modificar, organizar o influir en el comportamiento observable de un sistema generativo."

Un protocolo no implica:

- Acceso privilegiado.
 - Modificación del modelo.
 - Alteración de infraestructura.
 - Control de sistemas externos.
-

4. Principios de Investigación

P1 — Observabilidad

Toda afirmación debe basarse en resultados observables.

No se realizarán afirmaciones sobre mecanismos internos sin evidencia verificable.

P2 — Reproducibilidad

Todo experimento debe poder ser repetido por terceros.

P3 — Neutralidad

Los resultados deben registrarse independientemente de si confirman o rechazan la hipótesis.

P4 — No Interferencia

El experimento no debe alterar:

- Sistemas.

- Servicios.
 - Infraestructura.
 - Datos de terceros.
-

P5 — Seguridad Responsable

Toda publicación debe enfocarse en:

- comportamiento,
- riesgos potenciales,
- mitigaciones,

sin proporcionar instrucciones para abuso operativo.

5. Declaración de Uso Responsable

APSRF no constituye:

- un framework de explotación,
- un framework de intrusión,
- un framework de evasión,
- una metodología de acceso no autorizado.

La investigación tiene fines:

- académicos,
 - educativos,
 - científicos,
 - de seguridad defensiva.
-

6. Hipótesis Oficiales

H1

Los protocolos modifican comportamientos observables.

H2

Los protocolos producen cambios medibles.

H3

Los protocolos pueden amplificarse mediante capas intermedias.

H4

Las cadenas de protocolos generan efectos emergentes.

H5

Los efectos protocolarios poseen distintos niveles de persistencia.

7. Variables de Investigación

Variables Independientes

Elementos manipulados por el investigador.

Ejemplos:

- protocolo utilizado,
 - longitud del protocolo,
 - orden de protocolos,
 - número de capas,
 - ubicación del protocolo.
-

Variables Dependientes

Elementos medidos.

Ejemplos:

- calidad de respuesta,
 - consistencia,
 - persistencia,
 - estructura,
 - precisión.
-

Variables de Control

Elementos que deben permanecer constantes.

Ejemplos:

- modelo utilizado,
 - temperatura cuando exista acceso,
 - conjunto de tareas,
 - idioma,
 - contexto inicial.
-

8. Clasificación de Protocolos

Clase A

Formato

Clase B

Estructura

Clase C

Compresión

Clase D

Priorización

Clase E

Razonamiento

Clase F

Puente

Clase G

Persistencia

9. Escenarios Experimentales

Escenario 01

Sin protocolo.

Objetivo:

Establecer línea base.

Escenario 02

Protocolo único.

Objetivo:

Medir impacto individual.

Escenario 03

Protocolos encadenados.

Objetivo:

Medir amplificación.

Escenario 04

Protocolos contradictorios.

Objetivo:

Medir resistencia.

Escenario 05

Protocolos dinámicos.

Objetivo:

Medir adaptación.

Escenario 06

Bridge Protocol.

Objetivo:

Medir traducción contextual.

10. Dataset Experimental

Cada experimento utilizará el mismo conjunto de tareas.

Mínimo:

50 tareas.

Recomendado:

100 tareas.

Distribución:

- análisis,
 - síntesis,
 - creatividad,
 - razonamiento,
 - clasificación,
 - planificación,
 - resumen,
 - comparación.
-

11. Sistema de Puntuación

Cada métrica utiliza escala:

0 a 5.

0

Sin efecto observable.

1

Efecto mínimo.

2

Efecto leve.

3

Efecto moderado.

4

Efecto alto.

5

Efecto dominante.

12. Métricas Oficiales

Consistencia

Capacidad de mantener comportamiento.

Persistencia

Duración del efecto.

Transferencia

Capacidad de afectar distintas tareas.

Dominancia

Capacidad de imponerse sobre otros protocolos.

Adaptabilidad

Capacidad de coexistir.

Amplificación

Capacidad de aumentar efectos posteriores.

13. Registro de Evidencia

Cada experimento debe almacenar:

- fecha,
- plataforma,
- modelo,
- protocolo,
- prompt,
- respuesta,
- puntuaciones,
- observaciones.

Formato recomendado:

JSON.

14. Criterios de Validez

Un resultado se considera válido únicamente cuando:

- puede repetirse,
 - aparece múltiples veces,
 - supera la línea base,
 - genera diferencias observables.
-

15. Limitaciones

APSRF no permite inferir:

- funcionamiento interno,
- arquitectura propietaria,
- entrenamiento del modelo,
- diseño de seguridad interno.

Los resultados describen únicamente comportamientos observables.

16. Consideraciones Jurídicas

La investigación se limita a:

- observación,
- interacción autorizada,
- análisis comparativo,
- documentación científica.

No se realizan actividades destinadas a:

- eludir controles,
- obtener acceso privilegiado,
- acceder a información restringida,
- interferir con servicios.

Las conclusiones representan interpretaciones experimentales del comportamiento observable del sistema y no constituyen afirmaciones verificadas sobre la implementación interna de los proveedores.

17. Publicación Responsable

Toda publicación derivada de APSRF deberá incluir:

1. Objetivo de investigación.
 2. Metodología utilizada.
 3. Limitaciones del estudio.
 4. Resultados observados.
 5. Riesgos potenciales.
 6. Recomendaciones defensivas.
 7. Declaración de uso responsable.
-

18. Criterio de Éxito del Proyecto

El proyecto se considerará exitoso cuando pueda demostrar de forma reproducible que:

- los protocolos generan efectos observables,
- dichos efectos pueden medirse,
- dichos efectos pueden clasificarse,
- dichos efectos pueden reproducirse por terceros.

Sin necesidad de asumir modificaciones internas del modelo.

19. Próxima Fase

APSRF-BP1

Bridge Protocol Specification v1

Documento técnico destinado a definir:

- arquitectura del protocolo puente,
- reglas de interpretación,
- jerarquía de ejecución,
- flujo de procesamiento,
- mecanismos de evaluación.